複数言語の逐次学習による多言語モデルの分類タスク性能の検証

張　齡方，河原　大輔

早稲田大学

1. 概要

- **多言語モデルにおいて、複数言語にまたがる逐次学習（タスクを順番に学習する手法）の影響を検証**
  - 対象言語：**日本語・韓国語**
  - ニュース分類タスクを通じて、**知識転移と忘却の傾向**を分析

結果
- **学習順序によって初期精度に差が出るが、最終的には安定**
- 逐次学習における多言語モデルの挙動と課題が明らかに

2. 関連研究

- 多言語モデルによる知識転移
  - mBERT (multilingual BERT)：**一つの言語で学習した知識を他の言語に転移**
  - 特にゼロショット文法訂正や質問応答タスクにおける転移性能を確認（Hu et al., 2020; Yamashita et al., 2022）
- 逐次学習と破滅的忘却
  - 逐次的タスク学習では、**後続タスクが先行タスクの知識を上書き**し、性能が低下（Kirkpatrick et al., 2017）
- 多言語逐次学習の限界
  - 言語順序や学習タスクによって**知識転移の度合い・忘却の発生**が変動（Rajaee et al., 2024）

3. 手法と実験設定

- タスク： テキスト分類
  - カテゴリ：IT / 生活文化 / スポーツ
- ベースモデル： bert-base-multilingual-uncased
- 手法：ベースモデルの逐次学習（5回繰り返し）
  - 日本語→韓国語
  - 韓国語→日本語

逐次学習のイメージ（日→韓）

- データセット：
  - 日本語：Livedoor ニュースコーパス（3カテゴリに統合）
  - 韓国語：KLUE YNAT（日本語データセットのカテゴリに対応付け）

各言語の件数：約3,200件（train）＋800件（test）

4. 結果と考察

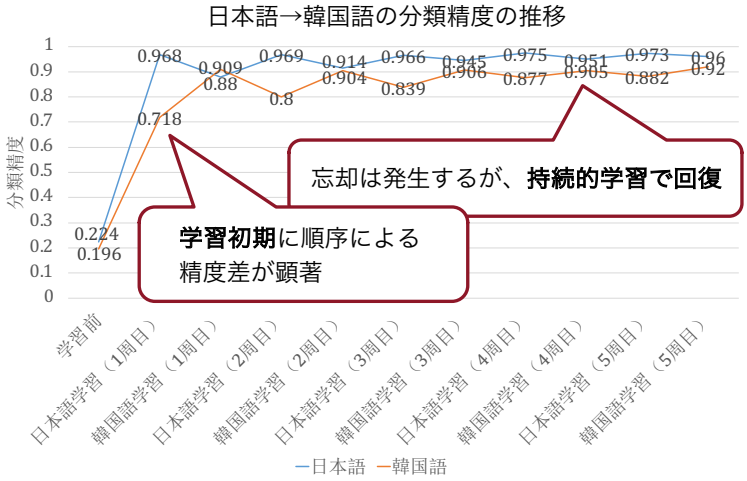

- 転移は**両方向で観測**される
- mBERTは言語間で**内部表現を共有**しているため、ある程度の知識保持が可能

5. 今後の展望

- 他言語における検証
- 忘却を抑制する継続学習手法の適用の検討

lingfang.zhang@fuji.waseda.jp